C++ AMP(Accelerated Massive Parallelism)

2013-03-29

고형호 <u>hyungho.ko@gmail.com</u>


http://hhko.tistory.com

목차


Part 1. 다중 프로세서 Part 2. 연산 자원 Part 3. GPU 특징 Part 4. 병렬화 프로그래밍 기술 Part 5. AMP Portability(이식성) Part 6. AMP Productivity(생산성) Part 7. AMP Performance(성능) Part 8. 정리

Part 1. 다중 프로세서

직렬 vs. 병행성 vs. 병렬성




프로세서 발전사



Part 2. 연산 자원

CPU

CPU(multi-core, 다중 프로세서) 자원 활용하기





직렬


Vs.

병렬










이제 CPU 자원 활용은 필수다.


GPU

연산 능력을 갖고 있는 자원은 CPU뿐인가?

GPU(Graphics Processing Unit)


그래픽 카드에 장착된 그래픽 연산장치






CPU GPU


AMD ATI Radeon HD 5870



병렬 하드웨어 아키텍처 분류




SISD vs. SIMD




배열 A와 B를 더하여라!





단일 명령으로 다중 데이터 처리





SIMD

(Single Instruction stream, Multiple Data stream)

SIMD 발전사

연도	СРИ	CPU 확장 명령어 셋	벡터 처리 능력 (벡터 레지스터 수)	
1996				
1997	펜티엄 P55C	MMX Multi Media eXtensions	64 비트	
1998				
1999	펜티엄 3 카트마이	SSE Streaming SIMD Extensions	128 비트	
2000			120 -1-	
2001	펜티엄 4 윌라멧	SSE 2		
2002				
2003				
2004	펜티엄 4 프레스캇	SSE 3		
2005				
2006	코어2 메롬			
2007	고이2 메콤			
2008	코어2 펜린	SSE 4		
2009	코어 i7 네할렘			
2010	웨스트미어			
2011	샌디 브릿지	Advanced Vector Extensions	256 비트	
2012				
2013				

SIMD 예제

```
for (unsigned int i = 0; i < MAX_SIZE2; i++)
{
     view_c[i] = view_a[i] + view_b[i];
}</pre>
```

view_c[i] = view_a[i] + view_b[i];


00AC121B mov eax,2625A0h

00AC1220 **movdqu xmm1,xmmword** ptr [ecx+edx]

00AC1225 **movdqu xmm0,xmmword** ptr [edx]

00AC1229 lea edx,[edx+10h]


00AC122C paddd xmm1,xmm0



이제 SIMD 연산은 일반화되고 있다.

Part 3. GPU 특징

CPU Vs. GPU



GPU 제약 사항

1. Recursion

8. goto or labeled statements

2. 'volatile'

9. throw, try, catch

3. virtual functions

10. globals or statics

4. pointers to functions

11. dynamic_cast or typeid

5. pointers to member functions

12. asm declarations

6. pointers in structs

13. Varargs


7. pointers to pointers

14. unsupported types

e.g. bool, char, short, long double

Part 4. 병렬화 프로그래밍 기술


병렬화 프로그래밍 기술의 발전사





병렬화 프로그래밍 기술 vs. 병렬성


기술 /병렬성	벡터 처리	루프 병렬성	태스크 병렬성	자원	
OpenMP	\circ	0	O	CPU	
ТВВ		0	0	CPU	
 ArBB	0	0		CPU	
Cilk Plus	Ο	Ο	Ο	CPU	
 PPL		Ο	Ο	CPU	
CUDA	Ο	Ο		GPU	
OpenCL	0	0		GPU	
AMP	Ο	Ο		GPU	

Part 5. AMP Portability(이식성)









restrict 예약어

```
double sin(double);
                                             // CPU
     double cos(double) restrict(amp);
                                             // GPU
     double tan(double) restrict(cpu, amp);
                                             // CPU, GPU
parallel_for_each(av.extent, [=](index<1> idx) restrict(amp)
{
        // sin(data.analge); // non amp restricted function
        cos(data.angle);
        tan(data.angle);
});
```

Part 6. AMP Productivity(생산성)

Productivity

Part of C++

STL-like library for

multidimensional data

Minimal API

Visual Studio integration

• • •

C++ to AMP

```
void AddArrays(int n, int * pA, int * pB, int * pC)
  for (int i=0; i<n; i++)
    pC[i] = pA[i] + pB[i];
```

```
#include <amp.h>
using namespace concurrency;
void AddArrays(int n, int * pA, int * pB, int * pC)
 array_view<int,1> a(n, pA);
                                  메모리
 array_view<int,1> b(n, pB);
 array_view<int,1> sum(n, pC);
 parallel_for_each( > 병렬처리
   sum.grid,
   [=](index<1> idx) restrict(amp) 누프로세서
      sum[idx] = a[idx] + b[idx];
```


AMP Vs. CUDA

```
#include <amp.h>
                                                  #include <cutil inline.h>
using namespace concurrency;
                                                  cudaMemcpy(dev A, InputA, size*sizeof(int),
void AddArrays(int n, int * pA, int * pB, int * pC)
                                                    cudaMemcpyHostToDevice);
                                                  cudaMemcpy(dev_B, InputB, size*sizeof(int),
 array_view<int,1> a(n, pA);
                                                    cudaMemcpyHostToDevice);
                                메모리
 array_view<int,1> b(n, pB);
                                                  VectorAdd<<<65535,512>>>(dev A, dev B, dev R);
 array view<int,1> sum(n, pC);
                           병렬
 parallel_for_each(
                                                  cudaMemcpy(Result, dev R, size*sizeof(int),
                           처리
    sum.grid,
                                                    cudaMemcpyDeviceToHost);
    [=](index<1> idx) restrict(amp)
                                                    global void VectorAdd( int*a, int*b, int*c)
      sum[idx] = a[idx] + b[idx];
                                       연산
                                                    int tid = blockIdx.x * blockDim.x+ threadIdx.x;
                                                    c[tid] = a[tid] + b[tid];
```

Part 7. AMP Performance(성능)


Morph

서로 다른 이미지를 자연스럽게 변화하는 과정이나 기법



Part 8. 정리

정리



이제 CPU 및 GPU 자원 활용은 필수다.

AMP Vs. CUDA

1. 이식성(Portability)



2. 생산성(Productivity)



3. 성능(Performance)



AMP_{\(\)}

성능이 요구되는 범용 클라이언트 프로그램에 적합

또는

생산성과 유지보수가 요구되는 서버/클라이언트 프로그램에 적합

CUDA는

성능이 요구되는 특화된 서버/클라이언트 프로그램에 적합

참고 자료

- 1. 프로그래머가 몰랐던 멀티코어 CPU 이야기, 김민장
- 2. Heterogeneous Computing and C++ AMP

http://channel9.msdn.com/Events/AMD-Fusion-Developer-Summit/AMD-

Fusion-Developer-Summit-11/KEYNOTE

3. Welcome to the Jungle

http://herbsutter.com/welcome-to-the-jungle/